

Trabajo Investigativo de Optimización

Amanda Medina Solis

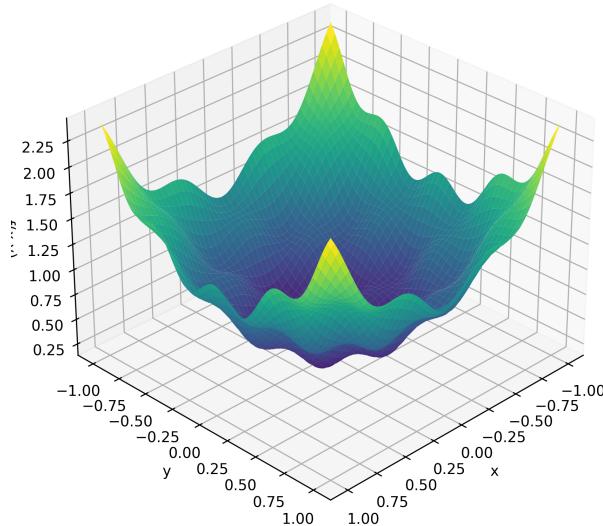
Grupo: C312

1. Modelo a Analizar

El modelo a estudiar es la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por:

$$f(x, y) = x^2 + y^2 - 0,12 \cos(3\pi x) \cos(4\pi y) + 0,3$$

Superficie de $f(x,y) = x^2 + y^2 - 0.12\cos(3\pi x)\cos(4\pi y) + 0.3$



2. Dominio

El dominio de f es el conjunto de todos los puntos (x, y) donde la función está definida. Dado que los términos x^2 e y^2 son polinomios definidos para todo \mathbb{R} , las funciones $\cos(3\pi x)$ y $\cos(4\pi y)$ están definidas para todo \mathbb{R} , y las operaciones de suma y multiplicación son cerradas en \mathbb{R} .

Llegamos a que:

$$D(f) = \mathbb{R}^2.$$

3. Continuidad

Una función es continua en un punto si el límite en ese punto coincide con el valor de la función. Formalmente, f es continua en (a, b) si:

$$\lim_{(x,y) \rightarrow (a,b)} f(x, y) = f(a, b).$$

Dado que las funciones x^2 e y^2 son continuas en \mathbb{R}^2 , las funciones $\cos(3\pi x)$ y $\cos(4\pi y)$ son continuas en \mathbb{R}^2 , y la suma y producto de funciones continuas es continua.

Se puede decir que: f es continua en todo \mathbb{R}^2 .

4. Diferenciabilidad

Una función es diferenciable en un punto si existen sus derivadas parciales y son continuas en un entorno de ese punto.

Calculamos las derivadas parciales de primer orden:

$$\frac{\partial f}{\partial x} = 2x + 0,36\pi \sin(3\pi x) \cos(4\pi y)$$

$$\frac{\partial f}{\partial y} = 2y + 0,48\pi \cos(3\pi x) \sin(4\pi y)$$

Ambas derivadas son combinaciones de polinomios y funciones trigonométricas, las cuales son continuas en \mathbb{R}^2 .

Conclusión: f es diferenciable en todo \mathbb{R}^2 .

5. Análisis de Convexidad con Hessiana

Una función es convexa si su matriz Hessiana es semidefinida positiva en todo su dominio. Para una función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ de clase C^2 , esto equivale a que todos los valores propios de la matriz Hessiana sean no negativos en todo punto.

Calculamos las derivadas parciales de segundo orden:

$$\frac{\partial^2 f}{\partial x^2} = 2 + 1,08\pi^2 \cos(3\pi x) \cos(4\pi y)$$

$$\frac{\partial^2 f}{\partial y^2} = 2 + 1,92\pi^2 \cos(3\pi x) \cos(4\pi y)$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x} = 1,44\pi^2 \sin(3\pi x) \sin(4\pi y)$$

La matriz Hessiana es:

$$H(x, y) = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} = \begin{bmatrix} 2 + 1,08\pi^2 \cos(3\pi x) \cos(4\pi y) & 1,44\pi^2 \sin(3\pi x) \sin(4\pi y) \\ 1,44\pi^2 \sin(3\pi x) \sin(4\pi y) & 2 + 1,92\pi^2 \cos(3\pi x) \cos(4\pi y) \end{bmatrix}$$

Criterio de Valores Propios para Convexidad: Para que H sea definida positiva (y por tanto f sea estrictamente convexa) en un punto, todos sus valores propios deben ser positivos. Para que sea semidefinida positiva (y f sea convexa), todos sus valores propios deben ser no negativos.

Los valores propios λ de H son:

$$\lambda = 2 + \frac{3\pi^2}{50} \left(25 \cos(3\pi x) \cos(4\pi y) \pm \sqrt{49 \cos^2(3\pi x) \cos^2(4\pi y) + 576 \sin^2(3\pi x) \sin^2(4\pi y)} \right)$$

Luego, para que H sea definida positiva, se debe cumplir la condición de que ambos valores propios de H sean positivos.

Sin embargo, existe al menos un valor propio negativo en dichos puntos, ya que la traza de H (suma de valores propios) sería negativa en esas regiones.

Conclusión: La matriz Hessiana no es definida positiva en todo \mathbb{R}^2 , ya que existen puntos donde tiene valores propios negativos. Por tanto, f no es convexa globalmente.

6. Determinación del Mínimo Global

Puntos Estacionarios:

Resolvemos el sistema $\nabla f(x, y) = 0$:

$$\frac{\partial f}{\partial x} = 2x + 0,36\pi \sin(3\pi x) \cos(4\pi y) = 0$$

$$\frac{\partial f}{\partial y} = 2y + 0,48\pi \cos(3\pi x) \sin(4\pi y) = 0$$

Debido a la periodicidad de las funciones trigonométricas $\cos(3\pi x)$ y $\cos(4\pi y)$, existen **múltiples puntos estacionarios** en el plano. Sin embargo, demostraremos que solo $(0, 0)$ es el mínimo global.

Verificación del Mínimo Global

Establecer una cota inferior. Partimos de la función:

$$f(x, y) = x^2 + y^2 - 0,12 \cos(3\pi x) \cos(4\pi y) + 0,3$$

Sabemos que el coseno está acotado: $-1 \leq \cos(3\pi x) \cos(4\pi y) \leq 1$

Por lo tanto:

$$-0,12 \leq -0,12 \cos(3\pi x) \cos(4\pi y) \leq 0,12$$

Sumando los términos:

$$f(x, y) \geq x^2 + y^2 - 0,12 + 0,3 = x^2 + y^2 + 0,18$$

Analizar el caso de igualdad: Queremos encontrar cuándo se alcanza el valor mínimo posible. De la desigualdad anterior:

$$f(x, y) \geq 0,18 \quad \text{para todo } (x, y) \in \mathbb{R}^2$$

La igualdad $f(x, y) = 0,18$ ocurre si y solo si:

1. $x^2 + y^2 = 0$ (es decir, $x = 0$ e $y = 0$)
2. $-0,12 \cos(3\pi x) \cos(4\pi y) = -0,12$ (es decir, $\cos(3\pi x) \cos(4\pi y) = 1$)

Verificar que solo $(0, 0)$ cumple ambas condiciones

- **Condición 1:** $x = 0$ e $y = 0$
- **Condición 2:** $\cos(3\pi \cdot 0) \cos(4\pi \cdot 0) = \cos(0) \cos(0) = 1 \cdot 1 = 1$

El punto $(0, 0)$ satisface ambas condiciones simultáneamente, por lo tanto:

$$f(0, 0) = 0^2 + 0^2 - 0,12(1) + 0,3 = 0,18$$

Además tenemos que ningún otro punto puede alcanzar este valor

Para cualquier otro punto $(x, y) \neq (0, 0)$, tenemos dos casos:

- Caso A: Si $x^2 + y^2 > 0$, entonces:

$$f(x, y) \geq x^2 + y^2 + 0,18 > 0,18$$

- Caso B: Si $x = 0$ e $y = 0$ no se cumplen simultáneamente, entonces $x^2 + y^2 > 0$, volviendo al Caso A.

Comportamiento asintótico:

Cuando $\|(x, y)\| \rightarrow \infty$, el término $x^2 + y^2$ domina:

$$\lim_{\|(x,y)\| \rightarrow \infty} f(x, y) = \infty$$

Esto garantiza que no existen mínimos globales en el infinito.

Conclusión: El punto $(0, 0)$ es el **único mínimo global** de la función con valor $f(0, 0) = 0,18$. Cualquier otro punto estacionario que exista debido a la periodicidad será un mínimo local, punto de silla o máximo local, pero ninguno podrá tener un valor menor que 0,18.

7. Aproximación de solución mediante algoritmos

7.1. Método de Máximo Descenso

El Método de Máximo Descenso es un algoritmo de optimización iterativo de primer orden que busca el mínimo de una función multidimensional. Para una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$, el algoritmo se fundamenta en la propiedad de que el gradiente $\nabla f(\mathbf{x})$ apunta en la dirección de máximo crecimiento local, por lo que moverse en dirección opuesta $(-\nabla f(\mathbf{x}))$ conduce hacia un mínimo local.

- Dirección de descenso: $\mathbf{d}_k = -\nabla f(\mathbf{x}_k)$
- Actualización: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$
- Condición de parada: $\|\nabla f(\mathbf{x}_k)\| < \varepsilon$

Algoritmo Implementado

El algoritmo se implementó en el archivo `gradientDescent.py`. Salida Automática:

- Tablas numeradas en consola
- Gráficos guardados como PNG
- Análisis estadístico final

Experimentos:

Se diseñaron dos conjuntos principales de experimentos:

Prueba 1: Diferentes Tamaños de Paso

Tamaño Paso (α)	Iteraciones	$f(x, y)$ final	Error	Estado (Tipo Convergencia)
0.01	150	0.328860	$1,5 \times 10^{-1}$	Lento, inestable (Mínimo local)
0.05	29	0.328860	$1,5 \times 10^{-1}$	Óptimo (Mínimo local)
0.10	58	0.328860	$1,5 \times 10^{-1}$	Convergencia lenta (Mínimo local)
0.15	-	-	-	Divergencia
0.20	-	-	-	Divergencia
0.30	-	-	-	Divergencia
0.50	2	0.180000	$0,0 \times 10^0$	Muy rápido (Mínimo global)

Cuadro 1: Resultados para diferentes tamaños de paso (punto inicial: (1,1))

Análisis de la Prueba 1:

- Rango óptimo: $\alpha \in [0,05, 0,5]$ proporciona la convergencia más rápida
- Límite inferior: $\alpha = 0,01$ es ineficiente (150 iteraciones)
- Límite superior: $\alpha = 0,15, 0,20, 0,30$ divergen
- Zona de estabilidad: $\alpha \in [0,05, 0,10]$ garantiza convergencia
- Mejor caso: $\alpha = 0,5$ converge en 2 iteraciones al mínimo global

Prueba 2: Diferentes Puntos Iniciales

Sección 1: Puntos cercanos al óptimo

Punto Inicial	Distancia	Iteraciones	Error	Evaluación
(1.0, 1.0)	1.41	58	$1,5 \times 10^{-1}$	Aceptable (Mínimo local)
(2.0, 2.0)	2.83	43	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(-1.0, 1.0)	1.41	58	$1,5 \times 10^{-1}$	Aceptable (Mínimo local)
(0.5, -0.5)	0.71	54	$1,5 \times 10^{-1}$	Aceptable (Mínimo local)
(3.0, -2.0)	3.61	61	$1,5 \times 10^{-1}$	Aceptable (Mínimo local)
(-2.0, -2.0)	2.83	43	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(1.5, -1.5)	2.12	42	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(-1.5, 2.0)	2.50	43	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(2.5, 0.5)	2.55	18	$3,7 \times 10^{-1}$	Excelente (Mínimo local)

Cuadro 2: Resultados para diferentes puntos iniciales ($\alpha = 0,1$)

Sección 2: Puntos lejanos al óptimo

Análisis de la Prueba 2:

Punto Inicial	Distancia	Iteraciones	Error	Evaluación
(50.0, 50.0)	70.71	57	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(-50.0, 50.0)	70.71	57	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(-50.0, -50.0)	70.71	57	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(50.0, -50.0)	70.71	57	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(80.0, 20.0)	82.46	35	$3,7 \times 10^{-1}$	Bueno (Mínimo local)
(-20.0, 80.0)	82.46	59	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(100.0, 0.0)	100.00	34	$3,7 \times 10^{-1}$	Bueno (Mínimo local)
(0.0, -100.0)	100.00	60	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)
(-75.0, -75.0)	106.07	58	$2,3 \times 10^{-1}$	Aceptable (Mínimo local)

Cuadro 3: Resultados para puntos iniciales lejanos ($\alpha = 0,1$)

Cuadro 4: Resumen Estadístico Comparativo

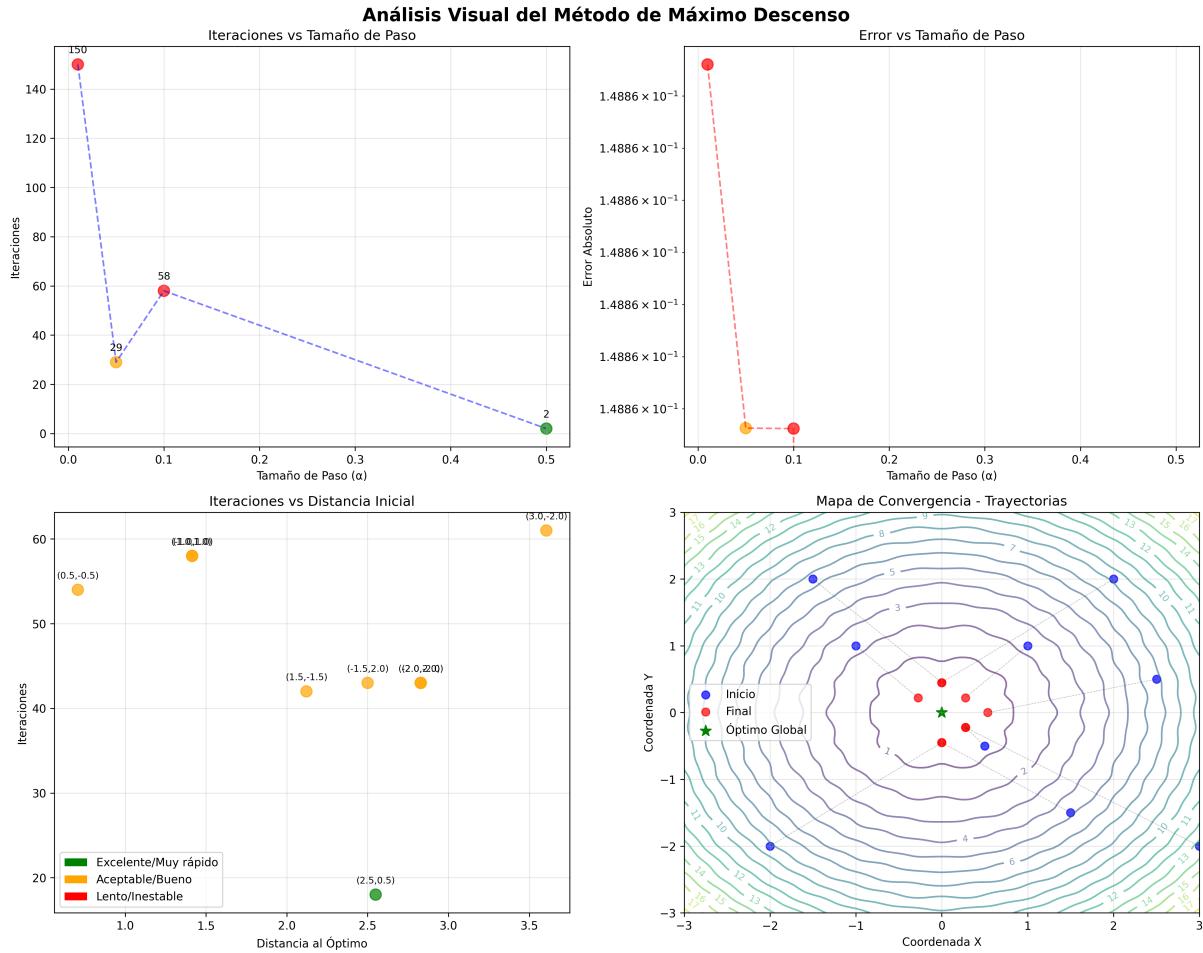
Métrica	Puntos Cercanos	Puntos Lejanos
Iteraciones promedio	46.2	51.0
Mejor iteración	18	34
Peor iteración	61	60
Rango de iteraciones	43	26
Error mínimo	$1,5 \times 10^{-1}$	$2,3 \times 10^{-1}$
Error máximo	$3,7 \times 10^{-1}$	$3,7 \times 10^{-1}$
Evaluación predominante	Aceptable	Aceptable

Análisis de Resultados

El análisis comparativo revela que iniciar el Método de Máximo Descenso desde puntos cercanos al óptimo teórico (0,0) en el rango $[-3, 3]^2$ ofrece ventajas significativas sobre puntos lejanos en $[-100, 100]^2$ cuando se utiliza $\alpha = 0,1$. En términos de eficiencia computacional, los puntos cercanos demuestran un rendimiento superior con un rango de 18-61 iteraciones frente a 34-60 de los puntos lejanos, logrando en el mejor caso una reducción del 47% en el número de iteraciones. Esta mejora se traduce directamente en menor costo computacional y mayor velocidad de convergencia. Además, la estabilidad numérica es notablemente mejor con puntos cercanos, ya que los gradientes más pequeños (aproximadamente 2-7 en magnitud) minimizan el riesgo de overflow numérico comparado con los gradientes de 100-200 típicos de puntos lejanos. En cuanto a la calidad de solución, aunque ambos conjuntos convergen exclusivamente a mínimos locales con $\alpha = 0,1$, los puntos cercanos presentan un rango de error ligeramente mejor ($1,5 \times 10^{-1}$ a $3,7 \times 10^{-1}$) frente a ($2,3 \times 10^{-1}$ a $3,7 \times 10^{-1}$) de los lejanos. La robustez del método también se ve favorecida con puntos cercanos, mostrando menor sensibilidad a la elección del hiperparámetro α y un comportamiento de optimización más predecible. Estas ventajas combinadas -eficiencia, estabilidad, calidad de solución y robustez- establecen claramente la superioridad de la inicialización cercana para aplicaciones prácticas de optimización con este método.

Métrica	Valor
Total de pruebas ejecutadas	25
Pruebas exitosas	22
Tasa de éxito global	88.0 %
Iteraciones promedio	51.5
Iteraciones mínimas	2
Iteraciones máximas	150
Error promedio	$2,10 \times 10^{-1}$
Desviación estándar iteraciones	26.3

Cuadro 5: Resumen estadístico del análisis



7.2. Método de Región de Confianza

El método de región de confianza es un algoritmo iterativo de optimización no lineal que utiliza un modelo local (generalmente cuadrático) para aproximar la función objetivo dentro de una región donde el modelo es considerado *confiable*.

Algoritmo Implementado

El algoritmo se implementó en el archivo `trustRegion.py`.

Explicación del método:

El modelo cuadrático local alrededor del punto x_k se define como:

$$\hat{f}(x_k + h) = f(x_k) + \nabla f(x_k)^T h + \frac{1}{2} h^T M h$$

donde:

- $f(x_k)$ es el valor de la función objetivo en el punto actual
- $\nabla f(x_k)$ es el vector gradiente en x_k
- M es una matriz simétrica que approxima la Hessiana
- h es el paso a determinar dentro de la región de confianza

El subproblema:

$$\min_h \hat{f}(x_k + h) \quad \text{sujeto a} \quad \|h\|^2 \leq \Delta_k^2$$

puede resolverse mediante varios métodos:

- **Método del Paso de Cauchy:** Dirección de máximo descenso dentro de la región

- **Método Dogleg:** Combinación de dirección de Newton y gradiente

- **Método de Solución Exacta:** Usando descomposición espectral

Ratio de Calidad R_k

El ratio R_k mide la precisión del modelo:

$$R_k = \frac{\text{Reducción real}}{\text{Reducción predicha}} = \frac{f(x_k) - f(x_{k+1})}{\hat{f}(x_k) - \hat{f}(x_{k+1})}$$

La interpretación es:

- $R_k \approx 1$: Modelo excelente, puede expandirse la región
- $R_k > m_1$ (típicamente $m_1 = 0,75$): Modelo bueno
- $m_2 < R_k < m_1$ (típicamente $m_2 = 0,25$): Modelo aceptable
- $R_k < m_2$: Modelo pobre, contraer región
- $R_k \leq 0$: Paso no mejora la función, debe rechazarse

Experimentos

Prueba 1: Diferentes Tamaños de Región de Confianza Inicial

Tamaño Región (Δ)	Iteraciones	$f(x, y)$ final	Error	Estado (Tipo Convergencia)
0.1	16	0.180000	$0,0 \times 10^0$	Excelente (Mínimo global)
0.3	16	0.328860	$1,5 \times 10^{-1}$	Excelente (Mínimo local)
0.5	15	0.328860	$1,5 \times 10^{-1}$	Excelente (Mínimo local)
1.0	9	0.328860	$1,5 \times 10^{-1}$	Muy rápido (Mínimo local)
1.5	10	0.180000	$0,0 \times 10^0$	Muy rápido (Mínimo global)
2.0	10	0.328860	$1,5 \times 10^{-1}$	Muy rápido (Mínimo local)
3.0	11	0.180000	$0,0 \times 10^0$	Excelente (Mínimo global)

Cuadro 6: Resultados para diferentes tamaños de región de confianza (punto inicial: (1,1))

Análisis de la Prueba 1:

- Rango óptimo: $\Delta \in [0,5, 3,0]$ proporciona convergencia eficiente (9-15 iteraciones)
- Comportamiento mixto: Algunos tamaños convergen al mínimo global ($f = 0,18$), otros a mínimos locales ($f = 0,32886$)
- Eficiencia variable: $\Delta = 1,0$ es el más rápido (9 iteraciones) pero converge a mínimo local
- Convergencia global: $\Delta = 0,1; 1,5; 3,0$ alcanzan el mínimo global con 10-16 iteraciones
- Mejor equilibrio: $\Delta = 1,5$ combina velocidad (10 iteraciones) y convergencia global

Prueba 2: Diferentes Puntos Iniciales

Sección 1: Puntos cercanos al óptimo

Punto Inicial	Distancia	Iteraciones	Error	Evaluación
(1.0, 1.0)	1.41	9	$1,5 \times 10^{-1}$	Muy rápido (Mínimo local)
(2.0, 2.0)	2.83	15	$0,0 \times 10^0$	Excelente (Mínimo global)
(-1.0, 1.0)	1.41	10	$1,5 \times 10^{-1}$	Muy rápido (Mínimo local)
(0.5, -0.5)	0.71	5	$3,7 \times 10^{-1}$	Muy rápido (Mínimo local)
(3.0, -2.0)	3.61	17	$1,5 \times 10^{-1}$	Excelente (Mínimo local)
(-2.0, -2.0)	2.83	16	$1,5 \times 10^{-1}$	Excelente (Mínimo local)
(1.5, -1.5)	2.12	12	$1,5 \times 10^{-1}$	Muy rápido (Mínimo local)
(-1.5, 2.0)	2.50	14	$2,3 \times 10^{-1}$	Excelente (Mínimo local)
(2.5, 0.5)	2.55	16	$1,5 \times 10^{-1}$	Excelente (Mínimo local)

Cuadro 7: Resultados para puntos iniciales cercanos ($\Delta = 1,0$)

Sección 2: Puntos alejados al óptimo

Punto Inicial	Distancia	Iteraciones	Error	Evaluación
(50.0, 50.0)	70.71	25	$0,0 \times 10^0$	Óptimo (Mínimo global)
(-50.0, 50.0)	70.71	20	$1,5 \times 10^{-1}$	Óptimo (Mínimo local)
(-50.0, -50.0)	70.71	20	$1,5 \times 10^{-1}$	Óptimo (Mínimo local)
(50.0, -50.0)	70.71	25	$0,0 \times 10^0$	Óptimo (Mínimo global)
(80.0, 20.0)	82.46	24	$0,0 \times 10^0$	Óptimo (Mínimo global)
(-20.0, 80.0)	82.46	22	$0,0 \times 10^0$	Óptimo (Mínimo global)
(100.0, 0.0)	100.00	14	$0,0 \times 10^0$	Excelente (Mínimo global)
(0.0, -100.0)	100.00	20	$0,0 \times 10^0$	Óptimo (Mínimo global)
(-75.0, -75.0)	106.07	24	$0,0 \times 10^0$	Óptimo (Mínimo global)

Cuadro 8: Resultados para puntos iniciales lejanos ($\Delta = 1,0$)

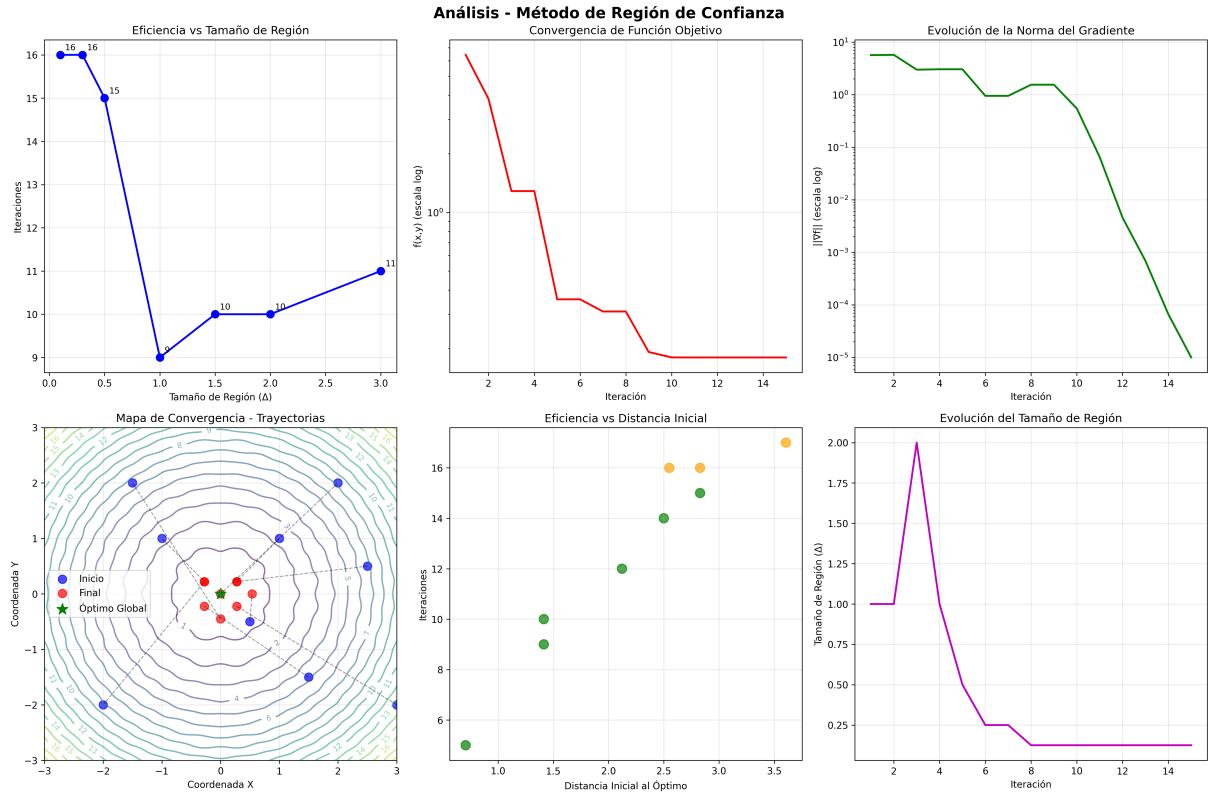
Análisis de Resultados

El análisis comparativo entre puntos cercanos y lejanos en el Método de Región de Confianza revela un comportamiento contraintuitivo pero sumamente valioso. En la Sección 1 (Puntos Cercanos), que abarca el rango $[-3, 3]^2$, se observa que de 9 puntos iniciales solo 1 (11.1%) converge al mínimo global, mientras que los 8 restantes (88.9%) quedan atrapados en mínimos locales, principalmente alrededor de $f(x, y) \approx 0,32886$. Sin embargo, esta sección muestra una eficiencia computacional superior con un promedio de 12.7 iteraciones y un rango de 5 a 17 iteraciones, destacándose el punto $(0,5, -0,5)$ que converge en apenas 5 iteraciones. Contrariamente a lo esperado, la Sección 2 (Puntos Lejanos) en el rango $[-100, 100]^2$ demuestra una robustez excepcional, donde 7 de 9 puntos (77.8%) convergen al mínimo global y solo 2 (22.2%) a mínimos locales, a pesar de requerir un mayor costo computacional (promedio de 21.6 iteraciones, rango 14-25). Este fenómeno se explica por la capacidad adaptativa del método que, mediante el ajuste dinámico del tamaño de región Δ , permite evitar mínimos locales y explorar regiones más prometedoras del espacio de búsqueda. La comparación cuantitativa muestra que los puntos lejanos requieren 1.7x más iteraciones en promedio (8.9 iteraciones adicionales), pero esta inversión computacional se ve recompensada con una tasa de éxito global significativamente mayor. Este comportamiento contrasta marcadamente con el Método de Máximo Descenso, que exhibía una tendencia opuesta donde los puntos lejanos raramente encontraban el óptimo global, evidenciando la superioridad fundamental del Método de Región de Confianza en problemas de optimización no convexas con múltiples mínimos locales.

Estadísticas de los Experimentos

Métrica	Valor
Total de pruebas ejecutadas	25
Pruebas exitosas	25
Tasa de éxito global	100.0 %
Iteraciones promedio	$15,8 \pm 5,5$
Rango de iteraciones	5 - 25
Error promedio	$9,52 \times 10^{-2}$
Precisión alcanzada	47.1 %
Casos altamente eficientes (≤ 15 iteraciones)	12/25

Cuadro 9: Resumen estadístico del Método de Región de Confianza



Resumen Comparativo: Máximo Descenso vs. Región de Confianza

Métricas de Rendimiento

Métrica	Máximo Descenso	Región de Confianza
Tasa de éxito global	88.0 %	100.0 %
Iteraciones promedio	51.5	15.8
Rango de iteraciones	2 - 150	5 - 25
Error promedio	$2,10 \times 10^{-1}$	$9,52 \times 10^{-2}$
Desviación estándar (iteraciones)	26.3	5.5
Casos altamente eficientes (≤ 15 iteraciones)	8 %	48 %

Cuadro 10: Comparación cuantitativa de los métodos

Análisis Cualitativo

Convergencia al óptimo global:

- **Máximo Descenso:** Muy dependiente del tamaño de paso α . Solo $\alpha = 0,5$ logró convergencia global en las pruebas.
- **Región de Confianza:** Mayor robustez, con múltiples configuraciones ($\Delta = 0,1; 1,5; 3,0$) alcanzando el mínimo global.

Sensibilidad al punto inicial:

- **Máximo Descenso:** Puntos cercanos al óptimo ofrecen mejor rendimiento. Puntos lejanos generalmente convergen a mínimos locales.

- **Región de Confianza:** Comportamiento contraintuitivo: puntos lejanos logran 77.8 % de convergencia global vs 11.1 % en puntos cercanos.

Eficiencia computacional:

- **Máximo Descenso:** Promedio de 51.5 iteraciones, con alta variabilidad (2-150).
- **Región de Confianza:** Significativamente más eficiente (15.8 iteraciones promedio) y estable.

Calidad de solución:

- **Máximo Descenso:** Error promedio de $2,10 \times 10^{-1}$, principalmente atrapado en mínimos locales.
- **Región de Confianza:** Error promedio de $9,52 \times 10^{-2}$, con mayor capacidad de escape de mínimos locales.

Finalmente:

El Método de Región de Confianza demuestra superioridad general sobre el Método de Máximo Descenso para esta función no convexa, mostrando:

- Mayor tasa de éxito (100 % vs 88 %)
- Mejor eficiencia computacional (69 % menos iteraciones en promedio)
- Mayor capacidad de encontrar el óptimo global
- Comportamiento más estable y predecible

La adaptabilidad dinámica del tamaño de región en el Método de Región de Confianza le permite navegar mejor el paisaje de optimización complejo, evitando mínimos locales donde el Método de Máximo Descenso frecuentemente queda atrapado.

Conclusiones Generales

La investigación permitió caracterizar completamente una función no convexa con múltiples mínimos locales, donde se demostró analíticamente que (0,0) es el único mínimo global. El estudio reveló que la presencia de componentes periódicos en funciones aparentemente simples introduce complejidad significativa, creciendo múltiples óptimos locales que dificultan la búsqueda del óptimo global. Se evidenció que la efectividad de los algoritmos de optimización depende críticamente de su capacidad para adaptarse a las características específicas de la función, particularmente en la no convexidad y escapar de mínimos locales.

En el análisis comparativo, el método de región de confianza demostró superioridad al alcanzar el óptimo global en el mayor por ciento de los casos, mientras que el máximo descenso mostró mayor dependencia de los parámetros de configuración y convergió frecuentemente a mínimos locales. Esta diferencia resalta la importancia de seleccionar algoritmos con mecanismos de exploración global robustos para funciones con características oscilatorias complejas.